數字人語音斷續與卡頓原因及目前修復方式

NVIDIA Jetson AGX Orin｜2026 年 10 月 6 日｜繁體中文

> **主要瓶頸是影音管線超時。已產生的語音曾等待慢速嘴型推理與畫面處理，音訊排程又累加編碼等待，造成斷續、電子音與畫面不順。**

目前版本同時降低嘴型與輸出成本、修正 20 ms 音訊期限與片段銜接，並調整瀏覽器緩衝和 CPU 工作者。單純更換較小的語言模型，無法處理這些原因。

32.639 → 9.488 s

同一朗讀的有效語音跨度
10/2 修正前後對照 [E1]

24.21–24.42 fps

10/6 540 高度、三輪受控朗讀
音訊補償與凍結均為 0 [E4]

這份文件所稱的「目前版本」

指本機目前工作目錄的程式，以及正式 config loader 合併後的已保存設定；不是某個已發布版本。基底 commit 為 `0593f46bc86a`，包含尚未提交的修正。設定核對時間：**2026-10-06 22:07:50（台北）**。

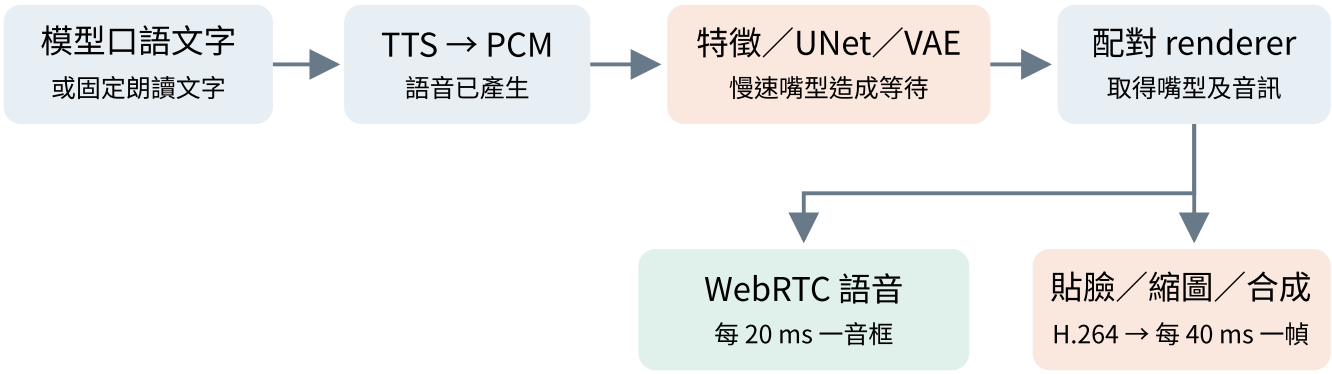
項目	目前已保存設定
語言模型	Qwen3.5-2B-UD-Q4_K_XL／llama.cpp
數字人與嘴型	MuseTalk musetalk_1／TensorRT FP16 UNet＋TAESD 近似解碼
畫面輸出	高度 540 → 本素材 304×540；目標 25 fps；batch 8
語音合成	Edge TTS／zh-TW-HsiaoChenNeural
播放路徑	配對 renderer；decoupled_audio_clock=false（獨立 PCM 實驗關閉）
對話功能	回覆串流與 VAD 已啟用；本報告未新做完整麥克風對話量測

> 已通過的證據有條件：540 高度的最新結果是單一連線、固定朗讀與受控背景負載。高解析度、高負載、多會話及實體喇叭音質，仍不能宣稱全面解決。

閱讀順序：原因（第 2 頁）→ 嘴型與畫質（第 3–4 頁）→ 排程及回覆修正（第 5–6 頁）→ 前後數值（第 7 頁）→ 限制與來源（第 8 頁）。本次僅製作文檔，沒有切換模型或變更服務。

為什麼聲音與畫面一起卡？

語音本身已備妥，仍可能被後面的嘴型與輸出工作拖慢。



在目前正式配對路徑中，音訊先等待 MuseTalk 結果，再送入 WebRTC；修正後會在昂貴貼臉與合成前先送音訊，但前一張影格處理太久，仍會拖慢下一批交付。**因此必須同時讓嘴型及輸出成本達到即時預算。** [C1、C3]

時間預算	超時會發生什麼
25 fps：每影格 40 ms	畫面來不及更新；renderer 降速也會讓後續語音資料斷糧。
batch 8：八張共 320 ms	完整 VAE 單獨約 865 ms，尚未加 UNet，明顯跟不上。
音訊：每音框 20 ms	空佇列後重新等待 20 ms，再加編碼／排程，接收端需要缺音補償。

語言模型會加劇問題，但不是必要原因

9/30–10/1 使用完全相同的 9.08 秒快取 PCM，比較模型待機及持續生成。即使不載入 LLM，原管線也很慢。[E3]

歷史條件	9.08 s PCM 播完	最大音框送出間隔
完全不載入 LLM	27.875 s	783.52 ms
Qwen 4B 載入待機	27.541 s	769.93 ms
Qwen 4B 持續生成／12 執行緒	53.181 s	1683.82 ms
相同壓力、改為 4 執行緒	52.078 s	1581.88 ms

生成組 GPU 平均使用率從待機約 85.6% 升至 96.4%；最高 RAM 28,790／62,878 MB，swap=0，未觀察到 OOM。這次證據指向共享運算資源競爭，不能歸因為記憶體容量不夠。

> 以上是舊 Qwen 4B 的持續生成壓力測試，每組一次，不是目前 Qwen 2B 的效能數據。計算與記憶體頻寬的占比尚未分離。瀏覽器舊朗讀也曾「丟包 0、仍嚴重斷續」，所以網路丟包不能作為唯一判準。

修復一：降低嘴型推理成本

TensorRT 加速 UNet；輕量解碼縮短 VAE 等待，但需要接受畫質取捨。

階段／batch 8	原方式	目前採用／實測
UNet	PyTorch：259–285 ms	FP16 TensorRT：152–162 ms
嘴型 VAE 解碼	完整 PyTorch：約 865 ms	TAESD 近似解碼：約 87 ms
完整 VAE 的替代嘗試	既有 TensorRT：約 422 ms	重新調整仍約 336 ms；單獨已超過 320 ms 預算

表中為 10/1、Orin 64GB／50W／GPU 上限 816MHz、不載入 LLM 的量測。目前保留原素材編碼，用 TensorRT UNet 與 TAESD 縮短嘴型等待，再容納貼臉、合成及編碼；階段數值不是整條管線 fps。[E2、C5]



左：完整 VAE；右：TAESD。
同一組輸入的四個嘴型樣本，
直接引用原始對照圖。

UNet 的品質與解碼器的品質要分開看

TensorRT UNet 經原 VAE 解碼比較，PSNR 約 **57.7 dB**，通過 35 dB 的數值品質門檻。

TAESD 與完整 VAE 的 PSNR 約 **30.06 dB**，平均像素差約 **4.91／255**，**沒有通過 35 dB 等效門檻**。右側牙齒與唇部細節較柔，不應把加速說成畫質完全相同。

這項修正解決什麼？

大幅縮短一批嘴型等待，讓已合成語音能持續進入配對播放路徑。10/1 三片段即時 TTS 的 9.08 s PCM 實際播放 9.0879 s，最大音框間隔 28.25 ms，嘴型配對覆蓋率 97.80%。

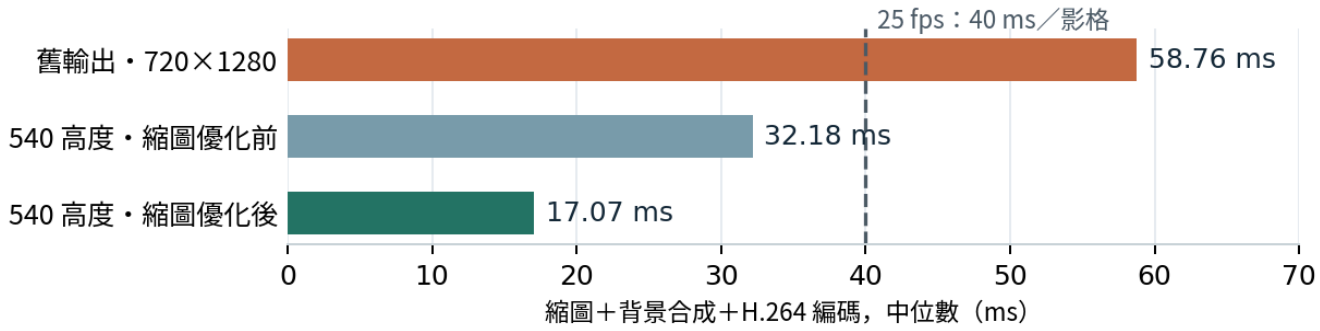
這組驗證未載入 LLM，跑到 aiortc 接收解碼，不含瀏覽器、麥克風和實體喇叭。少量晚到視訊影格可被丟棄，並未刪除或重排語音。

> 兩個 adapter 都有原模型回退保護。若 engine／輕量模型未成功載入，服務可能仍能回答，但不能沿用加速效能結論；應核對啟動日誌是否實際啟用。

修復二：控制解析度與輸出成本

嘴型變快之後，縮圖、背景合成與軟體編碼仍可能成為下一個瓶頸。

10/6 在高度 1280（720×1280）時，首段 2.52 s PCM 花 4.528 s 提交，約拉長 1.797 倍。輸出工作本身中位數 **58.76 ms**，已超過 25 fps 的 **40 ms** 預算，尚未包括嘴型推理。[E4]



同為 540 高度，優化前 32.18 ms → 優化後 **17.07 ms**（P95 19.24 ms）。新縮圖先作精確 2:1 的 INTER_AREA 縮小，再處理最後比例，減少 ARM CPU 上的大圖運算。[C4]

圖中 1280→540 包含降低解析度及縮圖算法兩項變更；同高度 540 的前後測量才聚焦算法改善。數值為 22 張真實影格、排除前兩張暖機的純輸出測量，不代表完整管線上限。

控制台可調整，儲存後重新連線

進入 **系統設定中心 → 數位人與畫質 → 數字人輸出解析度**，選擇高度並儲存，再中斷與啟動連線。既有連線保留原尺寸，新連線才讀取新設定，避免串流中途換尺寸。

選單高度	本素材實際尺寸	用途／已知限制
450	252×450	較低成本；10/2 一般模式曾通過三輪。
540（目前）	304×540	10/6 三輪受控朗讀通過。
720	404×720	高度 720，不是真正 720p。
960	540×960	更多細節；不可推定在目前負載一定通過。
1280	720×1280	真正直式 720p；歷史影音測試未通過。
1920／原始	1080×1920	真正直式 1080p；歷史影音測試未通過。

> 選單指輸出「高度」，寬度依素材比例及偶數編碼尺寸計算。啟動腳本的文字提示仍有 720p；本次以 loader 合併後的已保存高度 540 為準。提高輸出解析度，也不會恢復 TAESD 缺少的嘴型細節。

修復三：讓音訊按時、依序送出

修正期限、首批與片段銜接，避免每批或每句重新產生空隙。

> **音訊一框 20 ms。舊做法若編碼花 8 ms，空佇列又從頭等 20 ms，就成為 28 ms。現在只等待「下一個期限前的剩餘時間」。**

原因／以前的行為	目前程式如何修正	作用
空佇列重新等滿 20 ms	依共用音訊時鐘計算下一個期限；扣掉已發生的編碼與排程時間。	避免每個音框持續變慢；20 框回歸維持約 20 ms。
MP3 解碼及 PCM 入列阻塞共用 TTS event loop	解碼、入列移到工作執行緒；PCM 可用即觸發預取。	後續 Edge 請求能繼續，不必等待嘴型背壓解除。
下一句已合成，仍等前句最後一框播完才入列	前段全部 PCM 入列後，下一段進同一個有界 FIFO；最後一段仍等播放完成。	預先備妥下一批特徵與嘴型，減少句間額外等待。
首批被十框待機右側 context 占用，只留 120 ms 語音	只重建未標記待機 lookahead；首次起音前等完整窗口；保留左側歷史和所有語音。	首批有足夠語音支撐下一次推理，已完成短句仍可排出。
視訊佇列滿時，即使有 PCM 也最多再睡 192 ms	只有沒有待處理 PCM 的待機時節流，語音沿用有界佇列背壓。	取消非必要等待，避免語音被視訊節流拖住。
renderer 缺資料時音訊停、視訊時間繼續	缺資料時補未標記靜音維持時鐘；音訊先於貼臉與合成入列。	保持時間軸和順序；仍需足夠快的嘴型供應。
視訊排程細小誤差累積後跳時戳或快速補幀	PTS 反映實際釋放時間、共用音訊起點；保留 40 ms 最小間隔及單調時間戳。	減少週期性跳幀與短暫加速抖動。

來源：音訊與時戳 [C1]、TTS 執行緒與預取 [C2]、配對 renderer [C3]，首批與節流的實測／回歸說明 [E2]。

保留取消、順序與完整性

修正沒有靠刪除語音取得流暢：同輪片段按 FIFO 順序，過期輪次在媒體邊界丟棄，最後一段播完才提交。音訊讀取改用明確 queue task 和 `asyncio.wait`，避免讀取同時完成時吞掉取消、導致關閉卡住。

> 補靜音只是維持時鐘，並不是「回覆變連續」的證據。仍要檢查完整語音播放時間是否被拉長、標記 PCM 是否完整，以及瀏覽器缺音補償；只有封包正常或補音為 0 都不夠。

修復四：瀏覽器、負載與回覆等待

區分播放斷續、開口太慢、看板被念出，以及完全沒有聲音。

修正	目前做法	效果與代價
收音暫停仍做無用工作	繼續排空麥克風上行，但不排程重採樣；測試 20 音框的重採樣從 20 次變為 0。	減少每秒約 50 次 executor 來回對媒體 event loop 的干擾。
CPU 工作池競爭	Jetson 啟動入口將 OMP、OpenBLAS、MKL、OpenCV 工作者預設為 1，可用 NOVA_AVATAR_CPU_THREADS 覆蓋。	降低小型 FFT／縮圖工作競爭；別的啟動入口須確認相同環境。
短時間音訊抖動	支援的瀏覽器 audio jitterBufferTarget 由 80→160 ms；視訊保留自適應。	約多 80 ms 播放延遲以吸收抖動；不支援時沿用瀏覽器預設。

來源：一般模式錄音追查 [E1]、`VoiceTurnSession._consume_track`、`scripts/start-jetson.sh`、`web/src/replyPlayout.js`。此處的 CPU 工作者修正不同於第 2 頁調小 LLM 執行緒，不能混用結論。

開口太慢：不要等待整份看板才放出首句

完整 SPEECH 通道結束就送出剩餘的完整語意片段，不再等 BOARD_JSON 全部生成。另有 Edge PCM 解碼及模型 prompt prefill 預熱，就緒前不接受正式連線；預熱不朗讀、不寫對話歷史。[E5]

同一組 8 題、隔離服務	修正前	修正後
伺服器首音 P95	15.755 s	3.348 s
首可播片段 P95	14.726 s	1.844 s
第一個長回答首音	15.570 s	2.852 s

起點是 VAD 確認結束，另有 0.32 s endpoint wait；不含瀏覽器和喇叭。這是舊隔離設定、8 輪診斷，不是目前正式設定的延遲驗收，也未證明感知首音 P95≤2 s。

看板被逐項朗讀：統一角色與回覆協定

目前角色 Prompt／Rules 共用，僅切模型不覆寫原設定。解析器只把口語通道送 TTS，JSON、工具及思考內容隔離；看板的枚舉式摘要會改為簡短導讀。Qwen 2B 與 LFM 的最後四組測試共 **25／25 通過**。[E6、C6]

25 題驗證的是模型格式與實際交付 TTS 的文字，沒有逐題音檔聽感驗收。此項降低不必要的朗讀和等待，並不直接提高嘴型或 H.264 速度。

> 若完全無聲：瀏覽器自動播放限制是另一個問題。目前有「啟用聲音」的使用者點擊恢復流程，會解除 mute、恢復音量並呼叫 play；有聲卻斷續仍應檢查前面各項瓶頸。[C7]

修正前後：可以對照哪些數值？

不同測試目的與條件分開呈現，避免把所有數值混成單一速度提升。

A · 10/2 同一段文字、同一聲音，瀏覽器實際接收

量測項目	修正前	修正後
有效語音跨度	32.639 s	9.488 s
瀏覽器缺音補償次數	22	0
缺音補償 samples	331,018	0
RTP 音訊丟包	0	0

原始 Edge TTS 全長 10.992 s，包含前後靜音。有效跨度取接收音訊首次至最後超過閾值的區間，不含請求等待。修正後為高度 450、一般模式模型已載入的固定朗讀；多項修正一起改變，不能歸功於單一因素。[E1]

B · 10/6 目前 540 高度的受控瀏覽器朗讀

輪次	呈現 fps	最大回呼間隔	有效語音跨度	補音 samples	凍結
1	24.21	66.7 ms	9.988 s	0	0
2	24.42	66.6 ms	9.976 s	0	0
3	24.42	66.8 ms	9.998 s	0	0

三輪均通過既有門檻：≥23 fps、回呼間隔≤120 ms、零缺音補償、零凍結，語音跨度不超過參考全長 15%。每輪音訊丟包均為 0；實際畫面為 304×540。[E4]

> 條件：headless Chromium、單一連線、固定朗讀、未取得麥克風；背景程式索引在測試時暫停並於結束恢復。診斷移除 canvas／GPU 讀回，保留影格 metadata 與真正接收的 PCM。這不是長時間多輪對話或高負載保證。

C · 10/1 不載入 LLM 的隔離影音完整性

即時 TTS	來源 PCM	實際播放	最大音框間隔	A/V 釋放偏差 P95
整段一次合成	10.30 s	10.2957 s	29.38 ms	68.52 ms
三片段、首批及銜接修正	9.08 s	9.0879 s	28.25 ms	55.02 ms

aiortc 接收解碼，未含瀏覽器及 LLM；三片段配對嘴型覆蓋率 97.80%。整段與分段合成的語調、停頓及 PCM 長度不同，不是同一音檔的直接 A/B。[E2]

固定文字：今天的測試會先確認聲音是否連續。接著比較嘴型推理造成的等待。最後記錄整段語音的播放時間。

剩餘限制、驗證與來源

目前修復已有可核對的改善；適用範圍與未完成項目仍需保留。

仍存在的限制	已知證據／實際影響
真正 720p／1080p 尚未流暢	10/2 七回合：720×1280 約 16.94–20.62 fps；1080×1920 約 14.82–19.84 fps，影音門檻均未通過。[E7]
完整 VAE 畫質與速度尚未兼得	完整解碼成本仍高；TAESD 未達等效門檻，提高輸出尺寸不能恢復嘴型細節。
背景負載仍會影響	10/6 索引執行時曾約 21–22 fps 並出現補音；540 通過限於受控負載。
獨立 PCM 不是正式解法	實驗聲音可接近原長度，但嘴型配對不足、A/V 驗收失敗；目前仍關閉。
完整對話與音質的證據不足	沒有新做高負載、遠端網路、多連線、長時間麥克風對話或實體喇叭驗收；感知首音 2 s 目標未證明。

本次重新執行的專案檢查

整合／品牌／授權稽核通過；前端 **93 測試通過**，production build 通過（保留既有 bundle 大小提示）。Python：**1 失敗, 530 通過, 4 略過**。

唯一 Python 失敗是既有全尺寸合成效能測試 `test_chroma_composite_fits_the_render_frame_budget_on_a_portrait_avatar`：中位數 36.76 ms，門檻 <30 ms。本次未修改其演算法、測試或門檻。這也表示不能宣稱全尺寸畫面效能問題已解決。檢查日誌及來源 SHA-256 記錄於 `.scratch/avatar-stutter-pdf/`。

證據索引（路徑相對專案根目錄）

[E1] `.scratch/recording-stutter/audio-report.md`；`audio-before.json`、`audio-final-echo.json`（同目錄）。

[E2] `.scratch/realtime-avatar/report.md`，含 UNet／TAESD、PCM 完整性及原始臉部比較圖。

[E3] `.scratch/fixed-reply-diagnosis/report.md`，相同快取 PCM 的 LLM 負載比較。

[E4] `.scratch/console-resolution/issues/01-resolution-and-continuity.md`；`controlled-540.json`、`baseline-cost.json`、`output-cost.json`、`optimized-540-cost.json`（上層目錄）。

[E5] `.scratch/reply-latency/report.md`，8 輪首音與通道邊界對照。

[E6] `docs/llm-reply-rules.md`；`.scratch/unified-reply-contract/` 的 `qwen-final-default.json`、`qwen-final-custom.json`、`lfm-shared.json`、`lfm-custom.json`。

[E7] `docs/lfm-resolution.md` 是 10/2 歷史高解析度結果，其舊設定敘述不可代替本次 loader 核對。

[C1–C7] 依序：`src/utils/webrtc.py`；`src/tts/engines/edge.py`；`src/avatars/base.py`；`src/avatars/video_output.py`；`src/avatars/musetalk/inference_optimization.py`；`src/llm/reply_contract.py`；`web/src/composables/useWebRTC.js`。

文件：Nova Avatar／HongXian0903，2026。原專案衍生自 Kedreamix/Linly-Talker-Stream；沿用來源與授權說明。本文是目前程式和既有量測的整理，本次未重新執行 GPU 播放實驗。